

Trường Đại học Bách Khoa - Đại Học Đà Nẵng
Khoa Điện tử - Viễn thông



BÁO CÁO CUỐI KỲ
CHUYÊN ĐỀ 2

Đề tài: Ứng dụng học tăng cường và mô hình ngôn ngữ lớn trong tối ưu mạng tích hợp không gian– không trung – mặt đất (SAGIN)

Giảng viên hướng dẫn: TS. Nguyễn Văn Hiếu

Sinh viên thực hiện:

Nguyễn Hữu Minh - lớp 21KTMT2- 106210245

Trần Văn Tú - lớp 21KTMT2 - 106210258

Hoàng Khắc Trung Hiếu – lớp 21KTMT - 106210047

Đà Nẵng, 15/12/2025

MỤC LỤC

1. Phân công công việc.....	2
2. Giới thiệu bài toán	3
3. Mô hình hệ thống.....	4
3.1 Tổng quan hệ thống	4
3.2. Liên kết Backhaul FSO	6
3.2.1. Mô hình kênh vệ tinh – HAP.....	6
3.2.2 Mô hình kênh HAP – UAV	7
3.3 Dung lượng ergodic	9
3.4 Liên kết truy nhập RF	9
3.5 Liên kết gán kết nối (Link Association).....	10
3.6 Mô hình tiêu thụ năng lượng.....	11
4. Mô tả và giải quyết bài toán	12
4.1. Phát biểu bài toán và mục tiêu tối ưu	12
4.2. Phương pháp tối ưu	15
4.2.1 Mô hình MDP cho HAP.....	15
4.2.2 Mô hình MDP cho UAV	16
4.2.3 Cải thiện quyết định UAV bằng LLM.....	18
5. Đánh giá độ phức tạp/ hội tụ của hệ thống.....	20
6. Phân tích kết quả	24
6.1 Thiết lập môi trường đánh giá.....	24
6.2 Đánh giá kết quả	27
7. Kết luận	31

1. Phân công công việc

Họ và tên	Nhiệm vụ	Phần trăm đóng góp
Trần Văn Tú	Đọc và tìm hiểu các bài báo liên quan về handover vệ tinh	33%
	Tìm hiểu cách mô phỏng vệ tinh bằng giả lập, và bằng dữ liệu từ starlink	
	Thiết kế bài toán Markov để áp dụng Deep Reinforcement Learning cho bài toán tối ưu	
	Thử huấn luyện với nhiều mô hình và bài toán makrov khác nhau để tìm ra phương pháp tối ưu	
	Chạy mô phỏng các kết quả để so sánh	
Nguyễn Hữu Minh	Đọc và tìm hiểu các bài báo liên quan về uav placement	34%
	Mô phỏng kênh truyền	
	Tối ưu liên kết vệ tinh	
	Đọc cái tài liệu liên quan đến việc áp dụng LLM vào bài toán DRL	
	Đánh giá độ phức tạp của mô hình DRL	
Hoàng Khắc Trung Hiếu	Đọc và tìm hiểu các bài báo liên quan đến kênh truyền	33%
	Mô hình hóa bài toán tối ưu	
	Tối ưu data rate của user	
	Thử nghiệm nhiều phương pháp LLM khác nhau để hỗ trợ các UAV trong quá trình ra quyết định	

2. Giới thiệu bài toán

Bài toán đặt ra tập trung vào tối ưu hóa end-to-end cho mạng tích hợp không gian – không trung – mặt đất (Space–Air–Ground Integrated Network, SAGIN), trong đó kết hợp vệ tinh quỹ đạo thấp LEO (ví dụ Starlink), nền tảng bay cao tầng HAP (High-Altitude Platform) và UAV nhằm cung cấp kết nối băng rộng, độ trễ thấp và độ tin cậy cao cho người dùng di động trong môi trường động phức tạp.

Cụ thể, hệ thống phải đảm bảo dung lượng backhaul ổn định và liên tục thông qua các liên kết quang không dây (Free-Space Optical – FSO) giữa vệ tinh – HAP – UAV, trong khi vẫn duy trì hiệu quả truyền dẫn trong điều kiện thực tế khắc nghiệt. Các liên kết FSO tuy có lợi thế băng thông cực lớn và không cần cấp phép, nhưng lại nhạy cảm với suy hao khí quyển, đặc biệt là mây và nhiễu loạn khí quyển, được mô hình hóa thông qua CLWC (Cloud Liquid Water Content) biến thiên trong khoảng 0.1–0.5 g/m³. Điều này đòi hỏi chiến lược điều khiển và phân bổ tài nguyên thông minh để tránh nghẽn backhaul và gián đoạn dịch vụ.

Song song với đó, bài toán yêu cầu tối ưu vị trí và quỹ đạo của UAV để tối đa hóa tổng thông lượng người dùng (sum throughput) và đảm bảo chất lượng dịch vụ (QoS), trong bối cảnh:

- Vệ tinh LEO di chuyển với tốc độ rất cao (~ 7.5 km/s), làm thay đổi nhanh cấu trúc kết nối và vùng phủ,
- Người dùng di động ngẫu nhiên với vận tốc khoảng 1–5 m/s, gây biến động liên tục về nhu cầu và kênh truyền,
- Môi trường truyền dẫn biến đổi theo thời gian, với ảnh hưởng đồng thời của suy hao FSO, giới hạn dung lượng backhaul và nhiễu RF ở tầng truy nhập.

Về mặt ứng dụng, mô hình SAGIN này có ý nghĩa thực tiễn lớn. Trong các kịch bản thiên tai (ví dụ lũ lụt tại Việt Nam năm 2025), hạ tầng RF mặt đất thường bị phá hủy hoặc quá tải nghiêm trọng. Khi đó, việc triển khai nhanh các UAV kết nối lên HAP và vệ tinh LEO qua FSO cho phép khôi phục liên lạc khẩn cấp, hỗ trợ cứu hộ, truyền dữ liệu y tế và điều phối cứu nạn. Ở các khu vực đô thị đông đúc như TP.HCM, với mật độ khoảng 200 người dùng/km² và yêu cầu thông lượng tổng vượt 1 Gbps, kiến trúc SAGIN giúp giảm tải cho mạng mặt đất, mở rộng vùng phủ và đáp ứng nhu cầu dữ liệu bùng nổ.

Tính cấp thiết của bài toán càng trở nên rõ ràng trong bối cảnh 6G giai đoạn 2025–2030, khi:

- Nhu cầu dữ liệu được dự báo tăng gấp 1000 lần, kéo theo yêu cầu băng thông và độ linh hoạt vượt xa khả năng của RF truyền thống,
- Phổ RF ngày càng khan hiếm, trong khi FSO cung cấp băng thông siêu rộng (từ hàng trăm Gbps đến Tbps) ở dải tần không cần cấp phép,
- Chi phí handover trong mạng vệ tinh-UAV rất cao, có thể làm mất 10–20% dung lượng hiệu dụng nếu không được tối ưu,
- Giới hạn năng lượng của UAV (thời gian bay chỉ khoảng 1–2 giờ) đòi hỏi chiến lược điều khiển vị trí và truyền thông tiết kiệm năng lượng, tránh kiệt quệ tài nguyên.


Do đó, bài toán tối ưu SAGIN không chỉ nhằm tối đa hóa thông lượng, mà còn phải đảm bảo kết nối liên mạch, tiết kiệm năng lượng, giảm handover và tăng độ bền vững của mạng. Đây là một hướng nghiên cứu cốt lõi cho các hệ thống truyền thông thế hệ mới, đặc biệt trong việc thu hẹp khoảng cách số, hỗ trợ vùng sâu vùng xa, và xây dựng hạ tầng mạng linh hoạt, thích ứng cao cho tương lai 6G.

Tính mới:

- Các nghiên cứu trước đây chủ yếu chỉ dùng kênh RF trong kết nối vệ tinh thì nghiên cứu này áp dụng kênh truyền FSO cho ra băng thông lớn hơn
- Hơn nữa các bài toán về tối ưu vị trí UAV trước đây việc ảnh hưởng bởi mây vẫn chưa được xem xét đến, làm mất đi tính tổng quát khi áp dụng vào thực tế.
- Cuối cùng nghiên cứu này còn tích hợp thêm LLM vào việc ổn định mô hình học tăng cường (DRL) giúp mô hình hoạt động ổn định hơn và đem lại hiệu suất cao hơn.

3. Mô hình hệ thống

3.1. Tổng quan về hệ thống



Hình 1 : Mô hình hệ thống

Hình 1 minh họa kịch bản mạng đầu-cuối tích hợp các liên kết giữa vệ tinh, nền tảng cao tầng (HAP) và các UAV. Hệ thống này bao gồm một tập các vệ tinh quỹ đạo Trái Đất thấp (LEO), một HAP, và M UAV được triển khai nhằm cung cấp vùng phủ liên tục cho N người dùng di động (MU) thông qua các liên kết truy nhập vô tuyến (RF).

Các vệ tinh thiết lập các liên kết FSO tốc độ cao với HAP để truyền dữ liệu từ mạng lõi lên không gian trung gian, trong khi HAP cũng thiết lập các liên kết backhaul FSO tốc độ cao với các UAV, nhằm đảm bảo truyền dẫn dữ liệu hiệu quả giữa mạng lõi và các trạm gốc trên không. Tại mỗi thời điểm, HAP chỉ có thể kết nối với một vệ tinh duy nhất để hình thành liên kết backhaul FSO, đồng thời vẫn duy trì các liên kết backhaul với các UAV.

Việc lựa chọn vệ tinh cần được điều chỉnh động theo thời gian, phụ thuộc vào vị trí tức thời của vệ tinh và HAP, cũng như ảnh hưởng của các đám mây khác nhau tại vị trí của UAV. Quyết định lựa chọn vệ tinh có tác động trực tiếp đến dung lượng backhaul khả dụng của HAP, từ đó ảnh hưởng đến dung lượng backhaul mà HAP có thể phân bổ cho các UAV.

Mỗi UAV chịu trách nhiệm cung cấp kết nối cho một tập con người dùng mặt đất nằm trong vùng phủ của nó thông qua các liên kết RF. Số lượng người dùng được phục vụ phụ thuộc vào yêu cầu tốc độ dữ liệu của người dùng và dung lượng backhaul mà

HAP có thể cung cấp tại thời điểm đó. Những người dùng không được UAV phục vụ sẽ phải kết nối trực tiếp với HAP; tuy nhiên, tốc độ dữ liệu sẽ thấp hơn do suy hao truyền dẫn lớn trên khoảng cách dài.

Vòng đời của hệ thống được chia thành T khe thời gian bằng nhau theo giả thiết quasi-static, nghĩa là các điều kiện mạng được giả định không thay đổi trong mỗi khe thời gian. Liên kết FSO giữa vệ tinh và HAP chịu ảnh hưởng mạnh bởi sự hiện diện của nhiều vệ tinh LEO chuyển động nhanh, khiến chất lượng liên kết và quá trình lựa chọn vệ tinh thay đổi liên tục theo thời gian. Đồng thời, liên kết HAP–UAV cũng bị tác động đáng kể bởi các điều kiện khí quyển, đặc biệt là sự di chuyển và phân bố không đồng đều của các đám mây, dẫn đến suy hao tín hiệu biến thiên do thay đổi hàm lượng nước lỏng trong mây (CLWC).

Bên cạnh đó, mạng truy nhập RF tại tầng UAV liên tục thay đổi theo chuyển động của người dùng, khiến bài toán tối ưu hóa vị trí UAV theo thời gian trở nên đặc biệt phức tạp.

Để thuận tiện, ta ký hiệu tập chỉ số của các khe thời gian, người dùng di động, UAV và vệ tinh lần lượt là

$$\mathcal{T} = \{0, 1, \dots, T - 1\}, \mathcal{N} = \{1, 2, \dots, N\}, \mathcal{M} = \{1, 2, \dots, M\}, \mathcal{S} = \{1, 2, \dots, S\},$$

trong đó $\mathcal{T}, \mathcal{N}, \mathcal{M}, \mathcal{S}$ lần lượt biểu thị tổng số khe thời gian, người dùng di động, UAV và vệ tinh. Tương ứng, $t \in \mathcal{T}$ ký hiệu một khe thời gian cụ thể, $n \in \mathcal{N}$ là một người dùng di động, $i \in \mathcal{M}$ là một UAV, và $s \in \mathcal{S}$ là một vệ tinh cụ thể.

3.2. Liên kết Backhaul FSO

3.2.1. Mô hình kênh vệ tinh – HAP

Đối với liên kết backhaul giữa vệ tinh s và HAP tại khe thời gian t , ta xét hai thành phần suy hao chính, bao gồm suy hao tầng bình lưu $h_{a,s,t}^S$ và suy hao do sai lệch hướng của tia tới $h_{p,s,t}^S$.

Suy hao tầng bình lưu giữa vệ tinh s và HAP chủ yếu chịu ảnh hưởng bởi sự hấp thụ của aerosol trong tầng bình lưu và có thể được mô hình hóa bằng định luật Beer–Lambert [16]:

$$h_{a,s,t}^S = \exp(-\alpha H_{st} \sec(\xi_{s,t}^S)), \quad (1)$$

trong đó α là hệ số suy hao tầng bình lưu, H_{st} biểu thị độ dày thẳng đứng của lớp tầng bình lưu, và $\xi_{s,t}^S$ là góc thiên đỉnh của vệ tinh so với HAP. Các giá trị điển hình của α ứng với các mức độ hoạt động núi lửa khác nhau tại bước sóng $\lambda = 1550$ nm và độ cao HAP $H_R = 20$ km có thể được tìm thấy trong [17].

Mô hình tổng quát của sai lệch hướng trở giữa HAP đứng yên và vệ tinh đã được trình bày chi tiết trong [18, Mục III-A]. Hàm mật độ xác suất (PDF) của $h_{p,s,t}^S$ được biểu diễn như sau [18, Eq. (8)]:

$$f_{h_{p,s,t}^S}(h_{p,s,t}^S) = \frac{\phi_{m,s,t}^2}{A_{m,s,t}^{\phi_{m,s,t}^2}} (h_{p,s,t}^S)^{\phi_{m,s,t}^2 - 1}, 0 \leq h_{p,s,t}^S \leq A_{m,s,t}, \quad (2)$$

trong đó $A_{m,s,t}$ và $\phi_{m,s,t}^2$ được xác định trong [18, Mục III-A].

Với hệ số kênh tổng hợp vệ tinh–HAP $h_{s,t} = h_{a,s,t}^S h_{p,s,t}^S$, tỷ số tín hiệu trên nhiễu (SNR) tức thời tại HAP được xác định bởi:

$$\gamma_{s,t} = \frac{P_{s,t}^{\text{FSO}} h_{s,t}^2}{\sigma_n^2}, \quad (3)$$

trong đó $P_{s,t}^{\text{FSO}}$ là công suất phát FSO của vệ tinh và σ_n^2 là phương sai nhiễu tại bộ thu.

Sử dụng (1), (2) và (3), sau một số biến đổi toán học, PDF của $\gamma_{s,t}$ được biểu diễn như sau:

$$f_{\gamma_{s,t}}(\gamma_{s,t}) = \frac{\phi_{m,s,t}^2}{2\gamma_{s,t}} \left(\frac{\gamma_{s,t} \sigma_n}{A_{m,s,t} h_{a,s,t}^S P_{s,t}^{\text{FSO}}} \right)^{\phi_{m,s,t}^2/2}. \quad (4)$$

3.2.2. Mô hình kênh HAP – UAV

Đối với liên kết backhaul FSO giữa HAP và UAV tại khe thời gian t , kênh truyền chịu ảnh hưởng bởi ba yếu tố chính: suy hao do mây $h_{c,i,t}$, nhiễu loạn khí quyển $h_{a,i,t}^U$, và sai lệch hướng trở $h_{p,i,t}^U$.

Suy hao do mây được mô tả chính xác bằng định luật Beer–Lambert [18, Eq. (11)]:

$$h_{c,i,t} = \exp(-\sigma_{c,i,t} H_{cl} \sec(\xi_{i,t})), \quad (5)$$

trong đó $\sigma_{c,i,t}$ là hệ số suy hao, phụ thuộc vào tầm nhìn

$$V_{i,t} = 1.002(L_{c,i,t}M_{c,i,t})^{-0.6473} [18, Eq. (13)].$$

Ở đây, $L_{c,i,t}$ là hàm lượng nước lỏng trong mây (CLWC), $M_{c,i,t}$ là mật độ giọt nước, H_{cl} biểu thị chiều cao thẳng đứng của vùng mây, và $\xi_{i,t}$ là góc thiên đỉnh tương ứng với vị trí HAP.

Mô hình sai lệch hướng trở tổng quát giữa HAP và UAV đứng yên đã được trình bày trong [18, Mục III-B]. PDF của $h_{p,i,t}^U$ được cho bởi [18, Eq. (17)]:

$$f_{h_{p,i,t}^U}(h_{p,i,t}^U) = \frac{\phi_{m,i,t}^2}{A_{m,i,t}^{\phi_{m,i,t}^2}} (h_{p,i,t}^U)^{\phi_{m,i,t}^2-1}, 0 \leq h_{p,i,t}^U \leq A_{m,i,t}, \quad (6)$$

trong đó $A_{m,i,t}$ và $\phi_{m,i,t}^2$ được xác định trong [18, Mục III-B].

Đối với nhiễu loạn khí quyển, dao động cường độ tín hiệu FSO giữa HAP và UAV được mô hình hóa bằng phân bố log-normal:

$$f_{h_{a,i,t}^U}(h_{a,i,t}^U) = \frac{1}{\sqrt{2\pi}\sigma_{R,i,t}h_{a,i,t}^U} \exp\left[-\frac{(\ln h_{a,i,t}^U + \sigma_{R,i,t}^2/2)^2}{2\sigma_{R,i,t}^2}\right], \quad (7)$$

trong đó $\sigma_{R,i,t}^2$ là phương sai Rytov, được xác định bởi:

$$\sigma_{R,i,t}^2 = 2.25k_w^{7/6} \sec^{11/6}(\xi_{i,t}) \int_{H_u}^{H_a} C_{n,i,t}^2(h)(h - H_u)^{5/6} dh. \quad (8)$$

Ở đây, $k_w = 2\pi/\lambda$ là số sóng quang học ứng với bước sóng λ , H_a là độ cao khí quyển, và $C_{n,i,t}^2(h)$ là hệ số cấu trúc chiết suất, được mô hình hóa theo mô hình Hufnagel–Valley [5]:

$$C_{n,i,t}^2(h) = 0.00594 \left(\frac{v_{\text{wind}}}{27}\right)^2 (10^{-5}h)^{10} \exp\left(-\frac{h}{1000}\right) + 2.7 \times 10^{-6} \exp\left(-\frac{h}{1500}\right) + C_{n,i,t}^2(0) \exp\left(-\frac{h}{100}\right),$$

trong đó $C_{n,i,t}^2(0)$ là nhiễu loạn tại mặt đất và v_{wind} là tốc độ gió.

Với hệ số kênh tổng hợp HAP–UAV $h_{i,t} = h_{c,i,t}h_{a,i,t}^U h_{p,i,t}^U$, SNR tức thời tại UAV i được xác định bởi:

$$\gamma_{i,t} = \frac{(P_{i,t}^{\text{FSO}} h_{i,t})^2}{\sigma_{n,i}^2}, \quad (9)$$

trong đó $P_{i,t}^{\text{FSO}}$ là công suất phát FSO của HAP và $\sigma_{n,i}^2$ là phương sai nhiễu tại UAV i .

Từ (5)–(7) và (9), PDF của $\gamma_{i,t}$ được biểu diễn như sau:

$$f_{\gamma_{i,t}}(\gamma_{i,t}) = \frac{\phi_{m,i,t}^2}{4\gamma_{i,t}} \left(\frac{\sqrt{\gamma_{i,t}} \sigma_{n,i}}{A_{m,i,t} h_{c,i,t} P_{i,t}^{\text{FSO}}} \right)^{\phi_{m,i,t}^2} \times \text{erfc} \left(\frac{\ln \left(\frac{\sqrt{\gamma_{i,t}} \sigma_{n,i}}{A_{m,i,t} h_{c,i,t} P_{i,t}^{\text{FSO}}} \right) + \mu_{i,t}}{\sqrt{2} \sigma_{r,i,t}} \right) \exp \left[\frac{\sigma_{r,i,t}^2 \phi_{m,i,t}^2 (1 + \phi_{m,i,t}^2)}{2} \right], \quad (10)$$

với $\mu_{i,t} = 0.5 \sigma_{r,i,t}^2 (1 + 2\phi_{m,i,t}^2)$.

3.3. Dung lượng ergodic

Dung lượng ergodic của một liên kết FSO được biểu diễn tổng quát bởi:

$$C_{x,t}^{\text{FSO}} = \int_0^\infty B_x^{\text{FSO}} \log_2(1 + \gamma_{x,t}) f_{\gamma_{x,t}}(\gamma_{x,t}) d\gamma_{x,t}, \quad (11)$$

trong đó B_x^{FSO} và $\gamma_{x,t}$ lần lượt là băng thông phân bố và SNR tức thời của liên kết FSO giữa nút x và nút y tại khe thời gian t . Cụ thể, $C_{s,t}^{\text{FSO}}$ và $C_{i,t}^{\text{FSO}}$ lần lượt biểu thị dung lượng ergodic của các liên kết vệ tinh–HAP và HAP–UAV i .

3.4. Liên kết truy nhập RF

Các liên kết truy nhập RF được phân thành hai loại: có đường truyền thẳng (LoS) và không có đường truyền thẳng (NLoS) [8]. Suy hao đường truyền trong trường hợp LoS nhỏ hơn so với NLoS, do trong môi trường NLoS, tín hiệu từ UAV/HAP chịu ảnh hưởng mạnh của phản xạ và nhiễu xạ, dẫn đến tổn hao công suất lớn.

Suy hao đường truyền trung bình giữa người dùng n và HAP/UAV i được ước lượng bởi:

$$\eta_{n,i,t} = 20 \log_{10} \left(\frac{4\pi f_c d_{u,i,t}}{c} \right) + p_{n,i,t} \xi_{\text{los}} + (1 - p_{n,i,t}) \xi_{\text{nlos}}, \quad (12)$$

trong đó f_c là tần số sóng mang RF, $d_{u,i,t}$ là khoảng cách 3D giữa HAP/UAV i và người dùng n , và c là vận tốc ánh sáng. ξ_{los} và ξ_{nlos} lần lượt là suy hao bổ sung trung bình trong các trường hợp LoS và NLoS.

Xác suất tồn tại đường truyền LoS giữa HAP/UAV i và người dùng n được xác định bởi:

$$p_{n,i,t} = \frac{1}{1 + \alpha \exp[-\beta(\theta_{n,i,t} - \alpha)]}, \quad (13)$$

trong đó α và β là các hằng số phụ thuộc môi trường, $\theta_{n,i,t} = \arctan\left(\frac{z_0}{l_{n,i,t}}\right)$, z_0 là độ cao của HAP/UAV, và $l_{n,i,t}$ là khoảng cách ngang giữa người dùng n và HAP/UAV i .

Cuối cùng, tốc độ dữ liệu của người dùng n được phục vụ bởi HAP/UAV i tại khe thời gian t được xấp xỉ bằng công thức Shannon–Hartley:

$$R_{n,i,t}^{\text{UAV/HAP}} = \frac{B_{\text{RF}}}{N} \log_2 \left(1 + \frac{P_{i,t}^{\text{RF}} 10^{-\eta_{n,i,t}/10}}{N_{0,n}} \right). \quad (14)$$

3.5. Liên kết gán kết nối (Link Association)

Trong quá trình kết nối, mỗi người dùng sẽ được gán cho HAP hoặc UAV sao cho liên kết cung cấp tốc độ truyền dữ liệu tức thời lớn nhất. Gọi $\alpha_{n,i,t} \in \{0,1\}$ và $\beta_{n,t} \in \{0,1\}$ là các biến nhị phân, lần lượt biểu thị việc người dùng n được gán cho UAV i hoặc cho HAP tại khe thời gian t . Các UAV sẽ ưu tiên phục vụ những người dùng gần nó nhất. Khi đó, ràng buộc gán kết nối được viết như sau:

$$\sum_{i=1}^M \alpha_{n,i,t} + \beta_{n,t} = 1, \forall n, t. \quad (15)$$

Tương ứng, tốc độ đường xuống tại phía người dùng được xác định bởi:

$$R_{n,t} = \sum_{i=1}^M \alpha_{n,i,t} R_{n,i,t}^{\text{UAV}} + \beta_{n,t} R_{n,t}^{\text{HAP}}, \quad (16)$$

trong đó $R_{n,i,t}^{\text{UAV}}$ và $R_{n,t}^{\text{HAP}}$ lần lượt là tốc độ dữ liệu do UAV i và HAP cung cấp tại khe thời gian t .

Cần lưu ý rằng tổng tốc độ dữ liệu mà UAV i cung cấp cho các người dùng trong vùng phủ của nó không được vượt quá dung lượng backhaul của UAV đó, tức là:

$$\sum_{n=1}^N \alpha_{n,i,t} R_{n,i,t}^{\text{UAV}} \leq C_{i,t}^{\text{FSO}}.$$

Do đó, trong trường hợp tốc độ dữ liệu truyền tới người dùng n vượt quá giới hạn cho phép, kết nối giữa UAV i và người dùng đó sẽ bị ngắt, và người dùng sẽ được gán lại cho một UAV khác có tốc độ truyền dữ liệu tức thời lớn nhất.

3.6. Mô hình tiêu thụ năng lượng

Trong nghiên cứu này, chúng tôi sử dụng mô hình năng lượng đẩy (propulsion energy) cho UAV cánh quạt được đề xuất trong [19]. Do năng lượng tiêu thụ cho truyền thông là không đáng kể so với năng lượng đẩy, nên thành phần này được bỏ qua.

Gọi $v(t)$ là vận tốc UAV, $a_c(t)$ là gia tốc, và v_d là véc-tơ đơn vị biểu thị hướng chuyển động. Lực đẩy cần thiết tại mỗi cánh quạt được xác định bởi:

$$T_h(v, a_c) = \frac{1}{n_r} \left(m \| a_c \| + \frac{1}{2} \rho \| v \|^2 S_{FP} \right) v_d - mg, \quad (17)$$

trong đó n_r là số lượng cánh quạt, m là khối lượng UAV, ρ là mật độ không khí, S_{FP} là diện tích tương đương của bản phẳng, và g là véc-tơ gia tốc trọng trường.

Quỹ đạo UAV $u(t)$ thỏa mãn:

$$v(t) = \dot{u}(t), a_c(t) = \ddot{u}(t).$$

Do công suất đẩy phụ thuộc vào vận tốc và lực đẩy tức thời, tổng năng lượng tiêu thụ của UAV đến thời điểm t được xác định bởi:

$$E(t) = \int_0^t P(\dot{u}(\tau), T_h(\dot{u}(\tau), \ddot{u}(\tau))) d\tau, \quad (18)$$

trong đó $P(\cdot)$ là mô hình công suất đẩy được trình bày trong [19, Eq. (11)].

Trong thực tế, quỹ đạo UAV được tạo ra theo các bước thời gian rời rạc có độ dài Δt . Gọi véc-tơ vận tốc UAV tại bước t là $v_t \in \mathbb{R}^3$, được cập nhật theo hành động điều khiển đã chọn. Gia tốc tương ứng được tính bởi:

$$a_t = \frac{v_t - v_{t-1}}{\Delta t}.$$

Do công suất đẩy phụ thuộc vào độ lớn và hướng của véc-tơ vận tốc, cũng như lực đẩy cần thiết, các thay đổi đột ngột của vận tốc — سواء về hướng hoặc độ lớn — sẽ làm tăng chuẩn gia tốc $\|a_t\|$. Điều này dẫn đến lực đẩy lớn hơn tại mỗi cánh quạt và làm tăng công suất tiêu thụ tức thời.

Vì vậy, tổng năng lượng tiêu thụ của UAV tính đến bước thời gian t có thể được biểu diễn dưới dạng rời rạc:

$$E_t = \sum_{\tau=0}^{t-1} P(v_\tau, T_h(v_\tau, a_\tau)) \Delta t, \quad (19)$$

trong đó v_τ và a_τ lần lượt là các véc-tơ vận tốc và gia tốc tại bước thời gian τ .

Biểu thức này phản ánh một cách tự nhiên ảnh hưởng của các thay đổi đột ngột về hướng bay hoặc tốc độ: các góc rẽ gắt hoặc gia tốc lớn sẽ dẫn đến mức tiêu thụ công suất tức thời cao hơn, phù hợp với mô hình đẩy quadrotor được triển khai trong mã mô phỏng.

4. Mô tả và giải quyết bài toán

4.1. Phát biểu bài toán và mục tiêu tối ưu

Mục tiêu chính của khuôn khổ đề xuất là tối ưu hóa hiệu năng tổng thể của hệ thống tích hợp SAT–HAP–UAV, thông qua việc đồng thời xem xét hiệu quả truyền thông và chi phí vận hành.

Gọi $c_{s,t}$ là biến chỉ thị khả năng quan sát của vệ tinh $s \in \mathcal{S}$ tại khe thời gian t , trong đó $c_{s,t} = 1$ nếu vệ tinh có thể quan sát được từ HAP tại thời điểm t , và $c_{s,t} = 0$ trong trường hợp ngược lại. Tập các vệ tinh khả kiến tại thời điểm t được ký hiệu là

$$\mathcal{C}_{\text{HAP}}^t = \{s \mid c_{s,t} = 1, s \in \mathcal{S}\}.$$

Ngoài ra, ta định nghĩa biến nhị phân $z_{s,t}$ biểu thị trạng thái kết nối giữa HAP và vệ tinh s tại khe thời gian t , trong đó $z_{s,t} = 1$ nếu HAP kết nối với vệ tinh s , và $z_{s,t} = 0$ nếu không kết nối.

Sự kiện handover vệ tinh xảy ra khi vệ tinh kết nối với HAP tại thời điểm t khác với vệ tinh tại thời điểm $t - 1$. Để thuận tiện cho việc mô tả, ta định nghĩa vector liên kết vệ tinh–HAP:

$$\mathbf{Z}^t = [z_{1,t}, z_{2,t}, \dots, z_{S,t}].$$

Handover xảy ra khi $\mathbf{Z}^t \neq \mathbf{Z}^{t-1}$, và mỗi lần handover sẽ phát sinh một chi phí $\phi_t = \xi$; nếu không có handover thì $\phi_t = 0$.

Hàm mục tiêu 1: Lựa chọn vệ tinh và tối ưu dung lượng đường trục

Mục tiêu thứ nhất nhằm giảm số lần handover giữa HAP và các vệ tinh, đồng thời tối đa hóa thời gian khả kiến và dung lượng đường trục mà vệ tinh cung cấp cho HAP. Bài toán tối ưu được biểu diễn như sau:

$$\max_{z_{s,t}} \sum_{t=0}^{T-1} \sum_{s \in \mathcal{C}_{\text{HAP}}^t} z_{s,t} (w_v v_{s,t} + w_b B_{s,t}) - \phi_t, \quad (20)$$

trong đó $v_{s,t}$ và $B_{s,t}$ lần lượt là thời gian khả kiến và dung lượng đường trục mà vệ tinh s cung cấp tại khe thời gian t ; w_v và w_b là các hệ số trọng số. Biến quyết định là $z_{s,t}$ biểu diễn cho liên kết giữa vệ tinh s và HAP tại thời điểm t .

Hàm mục tiêu 2: Tối đa hóa tốc độ dữ liệu người dùng

Mục tiêu thứ hai là tối đa hóa tổng tốc độ dữ liệu của người dùng trong mạng truy nhập UAV. Gọi $R_{n,t}$ là tốc độ dữ liệu của người dùng n tại khe thời gian t . Bài toán tối ưu được biểu diễn như sau:

$$\max_{\mathbf{p}} \sum_{t=0}^{T-1} \sum_{n=1}^N R_{n,t}, \quad (21)$$

trong đó $\mathbf{p} = \{x_{i,t}^{\text{UAV}}, y_{i,t}^{\text{UAV}} | \forall i, t\}$ là biến quyết định biểu diễn cho tập vị trí của tất cả các UAV trong suốt khoảng thời gian xét, và $R_{n,t}$ được tính theo (16).

Bài toán tối ưu hợp nhất

Hai mục tiêu trên được tích hợp vào một khuôn khổ tối ưu thống nhất nhằm cân bằng giữa tối đa hóa tốc độ dữ liệu người dùng và duy trì kết nối vệ tinh liên tục. Bài toán tối ưu hợp nhất được phát biểu như sau:

$$\max_{\{\mathbf{p}, \mathbf{z}_{s,t}\}} \sum_{t=0}^{T-1} [\gamma_1 \sum_{n=1}^N R_{n,t} + \gamma_2 \sum_{s \in \mathcal{C}_{\text{HAP}}^t} z_{s,t} (w_v v_{s,t} + w_b B_{s,t}) - \gamma_2 \phi_t], \quad (22)$$

với các ràng buộc:

$$z_{s,t} \in \{0,1\}, \forall s \in \mathcal{C}_{\text{HAP}}^t, \quad (22a)$$

$$\sum_s z_{s,t} = 1, \forall t, \quad (22b)$$

$$\sum_s z_{s,t} B_{s,t} \geq \sum_{i \in \mathcal{M}} U_{i,t}, \forall t, \quad (22c)$$

$$\alpha_{n,i,t}, \beta_{n,t} \in \{0,1\}, \forall n, i, t, \quad (22d)$$

$$\sum_{i=1}^M \alpha_{n,i,t} + \beta_{n,t} = 1, \forall n, t, \quad (22e)$$

$$\sum_{n=1}^N \alpha_{n,i,t} R_{n,i,t}^{\text{UAV}} \leq U_{i,t}, \forall i, t, \quad (22f)$$

$$x_{\min} \leq x_{i,t}^{\text{UAV}} \leq x_{\max}, \forall i, t, \quad (22g)$$

$$y_{\min} \leq y_{i,t}^{\text{UAV}} \leq y_{\max}, \forall i, t. \quad (22h)$$

Trong đó, $U_{i,t}$ là dung lượng đường trục mà HAP phân bổ cho UAV i tại thời điểm t , còn γ_1 và γ_2 là các hệ số điều chỉnh mức độ ưu tiên giữa hai mục tiêu tối ưu.

Ràng buộc (22b) và (22c) đảm bảo rằng tại mỗi khe thời gian, HAP chỉ kết nối với một vệ tinh duy nhất và dung lượng đường trục do vệ tinh cung cấp phải đủ để HAP phân bổ cho các UAV. Ràng buộc (22e) đảm bảo mỗi người dùng chỉ được gán cho một thực thể phục vụ duy nhất tại một thời điểm. Ràng buộc (22f) đảm bảo tổng tốc độ dữ liệu mà mỗi UAV cung cấp không vượt quá dung lượng đường trục của nó. Các ràng buộc (22g) và (22h) giới hạn vị trí hoạt động của UAV trong khu vực phục vụ.

Nhận xét

Bài toán tối ưu trên có tính phi tuyến và không lồi, do sự tồn tại của các biến quyết định rời rạc, mô hình kênh phi tuyến và điều kiện mạng biến thiên theo thời gian. Chuyển động nhanh của vệ tinh LEO, tính di động của người dùng, sự thay đổi dung lượng đường trục và các yếu tố môi trường khiến các phương pháp tối ưu truyền thống gặp nhiều khó khăn và yêu cầu chi phí tính toán lớn.

Để giải quyết các thách thức này, khung học tăng cường sâu (DRL) được áp dụng nhằm cho phép học thích nghi và ra quyết định theo thời gian thực. Bài toán tổng thể được phân tách thành nhiều mục tiêu con: hai mục tiêu đầu được huấn luyện đồng thời bằng mô hình DRL kết hợp đơn tác tử và đa tác tử, trong khi mục tiêu cuối cùng.

4.2. Phương pháp tối ưu

Để đồng thời tối ưu 2 mục tiêu, một khung học tăng cường sâu (DRL) lại được đề xuất, bao gồm hai mô-đun học cộng tác. Cụ thể, một mô hình học tăng cường đơn tác tử (SARL) được xây dựng cho nền tảng bay cao (HAP) nhằm quản lý việc lựa chọn vệ tinh, trong khi mô hình học tăng cường đa tác tử (MADRL) được sử dụng cho các UAV để tối ưu vị trí UAV phục vụ nhiều người dùng.

Để triển khai thuật toán dựa trên DRL, bài toán tối ưu được mô hình hóa dưới dạng Quá trình quyết định Markov (MDP).

4.2.1. Mô hình MDP cho HAP

Tại thời điểm t , quan sát của HAP, ký hiệu là s_t^{HAP} , được đưa vào mạng nơ-ron để xác định hành động tiếp theo. Quan sát này bao gồm thông tin môi trường hiện tại, cụ thể là vector thời gian nhìn thấy và vector dung lượng FSO của tất cả các vệ tinh tại thời điểm hiện tại. Trong đó, phần tử đầu tiên của mỗi vector tương ứng với vệ tinh mà HAP đã kết nối ở thời điểm trước đó.

Ngoài hai vector này, quan sát còn bao gồm dung lượng backhaul hiện tại của mỗi UAV, được xác định dựa trên vị trí UAV tại cùng thời điểm t .

Quan sát của HAP tại thời điểm t được định nghĩa như sau:

$$s_t^{\text{HAP}} = \{V_t, B_t, U_{i,t} \ (\forall i \in \mathcal{M})\} \quad (23)$$

trong đó V_t là vector thời gian nhìn thấy của các vệ tinh, B_t là vector dung lượng FSO (CFSO), và $U_{i,t}$ biểu diễn dung lượng backhaul của UAV thứ i tại vị trí hiện tại.

Không gian hành động của HAP, ký hiệu là $\mathcal{A}_{\text{HAP}}$, tương ứng với việc lựa chọn liên kết vệ tinh tại mỗi khe thời gian. Tại thời điểm t , HAP xác định hành động a_t^{HAP} dựa trên quan sát s_t^{HAP} .

Hành động 0 biểu thị việc duy trì kết nối với vệ tinh cũ, trong khi các hành động còn lại $a_t^{\text{HAP}} \in \{1, 2, \dots, N_s\}$ tương ứng với việc thiết lập liên kết mới với một vệ tinh trong tập ứng viên $\mathcal{C}_t^{\text{HAP}}$.

Sau khi thực hiện hành động, HAP nhận được phần thưởng từ môi trường. Hàm phần thưởng được thiết kế sao cho phù hợp với mục tiêu tối ưu tổng thể của hệ thống:

$$r_t^{\text{HAP}} = \begin{cases} -\zeta, & \text{nếu } B_{a_t^{\text{HAP}}}^t < \sum_{i \in \mathcal{M}} U_i^t, \\ -\xi, & \text{nếu } a_t^{\text{HAP}} \neq 0 \text{ và } B_{a_t^{\text{HAP}}}^t \geq \sum_{i \in \mathcal{M}} U_i^t, \\ w_v v_{a_t^{\text{HAP}}}^t + w_b B_{a_t^{\text{HAP}}}^t, & \text{trường hợp còn lại.} \end{cases} \quad (24)$$

4.2.2. Mô hình MDP cho UAV

Tại thời điểm t , UAV thứ i thu thập quan sát $s_{i,t}^{\text{UAV}}$ và sử dụng nó làm đầu vào cho mạng nơ-ron để quyết định hành động tiếp theo. Quan sát này bao gồm vị trí UAV hiện tại, vị trí của các UAV khác, bản đồ nhiệt người dùng, và bản đồ nhiệt mây trong khu vực hoạt động.

Bản đồ nhiệt người dùng biểu diễn sự phân bố không gian của người dùng bằng cách chia khu vực thành các ô lưới, trong đó mỗi ô cho biết số lượng người dùng hiện diện. Việc sử dụng bản đồ nhiệt thay vì tọa độ thô giúp giữ kích thước đầu vào cố định, tăng tính ổn định và hiệu quả huấn luyện trong môi trường động.

Quan sát của UAV i tại thời điểm t được định nghĩa như:

$$s_{i,t} = [(x_{i,t}^{\text{UAV}}, y_{i,t}^{\text{UAV}}), \{(x_{j,t}^{\text{UAV}}, y_{j,t}^{\text{UAV}}) \mid j \in \mathcal{M}, j \neq i\}, H_{i,t}^{\text{user}}, H_t^{\text{clwc}}] \quad (25)$$

Không gian hành động của UAV i là $\mathcal{A}_{\text{UAV}} = \{0,1,2,3,4\}$, trong đó các hành động từ 0 đến 3 tương ứng với việc UAV di chuyển Đông, Tây, Bắc, Nam, và hành động 4 biểu thị giữ nguyên vị trí.

Hàm phần thưởng cho UAV

Phần thưởng của UAV kết hợp phần thưởng cục bộ và phần thưởng toàn cục nhằm cân bằng giữa hiệu suất cá nhân và hợp tác hệ thống:

$$r_{i,t}^{\text{UAV}} = w g_t + (1 - w) l_{i,t} \quad (26)$$

Phần thưởng toàn cục:

$$g_t = \begin{cases} w_g \sum_{i=1}^M \sqrt{R_{i,t}^{\text{UAV}} U_{i,t}}, & \text{nếu } R_{i,t}^{\text{UAV}} \geq R_i^{\text{thres}}, \forall i \\ w_g \sum_{i=1}^M \sqrt{R_{i,t}^{\text{UAV}} U_{i,t}} - 1, & \text{ngược lại} \end{cases} \quad (27)$$

Phần thưởng cục bộ:

$$l_{i,t} = \begin{cases} w_l \sqrt{R_{i,t}^{\text{UAV}} U_{i,t}} - n_{c,i} p, & R_{i,t}^{\text{UAV}} \geq R_i^{\text{thres}} \\ w_l \sqrt{R_{i,t}^{\text{UAV}} U_{i,t}} - n_{c,i} p - 1, & \text{ngược lại} \end{cases} \quad (28)$$

Trong đó $n_{c,i}$ là số UAV có vùng phủ chồng lấn với UAV i , và p là hệ số phạt cố định nhằm khuyến khích các UAV phân tán để mở rộng vùng phủ.

Algorithm 1 Joint Training Algorithm for HAP and UAV Agents

```

1: for each UAV  $i$  do
2:   Initialize replay buffer  $D_i^{UAV}$  with capacity  $C$ 
3:   Initialize  $Q_i$  network with random weights  $\theta_i^{UAV}$ 
4:   Initialize target network  $\hat{Q}_i$  with  $\hat{\theta}_i^{UAV} \leftarrow \theta_i^{UAV}$ 
5: end for
6: Initialize replay buffer  $D^{HAP}$  with capacity  $C$ 
7: Initialize  $Q$  network with random weights  $\theta^{HAP}$ 
8: Initialize target network  $\hat{Q}$  with  $\hat{\theta}^{HAP} \leftarrow \theta^{HAP}$ 
9: for each episode do
10:   Reset the network environment
11:   for each time slot  $t$  do
12:     Obtain current backhaul capacity of each UAV
13:     Obtain observation  $s_t^{HAP}$  from the environment
14:     Select action  $a_t^{HAP}$  using the  $\epsilon$ -greedy policy
15:     Execute  $a_t^{HAP}$  and observe reward  $r_t^{HAP}$ 
16:     for each UAV  $i$  do
17:       Obtain observation  $s_{i,t}^{UAV}$  from the environment
18:       Select action  $a_{i,t}^{UAV}$  using the  $\epsilon$ -greedy policy
19:       Execute  $a_{i,t}^{UAV}$  and perform user association
20:     end for
21:     Update the environment
22:     Obtain next backhaul capacity of each UAV
23:     Observe next state  $s_{t+1}^{HAP}$ 
24:     Store transition  $(s_t^{HAP}, a_t^{HAP}, r_t^{HAP}, s_{t+1}^{HAP})$  in  $D^{HAP}$ 
25:     Sample random minibatch from  $D^{HAP}$ 
26:     Compute target Q-value  $y_t^{HAP}$  according to (36)
27:     Update  $\theta^{HAP}$  by minimizing (34)
28:     Update  $\hat{Q}^{HAP} \leftarrow Q^{HAP}$  every fixed number of steps
29:     for each UAV  $i$  do
30:       Observe reward  $r_{i,t}^{UAV}$  and next state  $s_{i,t+1}^{UAV}$ 
31:       Store transition  $(s_{i,t}^{UAV}, a_{i,t}^{UAV}, r_{i,t}^{UAV}, s_{i,t+1}^{UAV})$  in  $D_i^{UAV}$ 
32:       Sample random minibatch from  $D_i^{UAV}$ 
33:       Compute target Q-value  $y_{i,t}^{UAV}$  according to (36)
34:       Update  $\theta_i^{UAV}$  by minimizing (34)
35:       Update  $\hat{Q}_i^{UAV} \leftarrow Q_i^{UAV}$  every fixed number of steps
36:     end for
37:   end for
38: end for

```

Luồng dùng cho quá trình huấn luyện


4.2.3 Cải thiện quyết định UAV bằng LLM

Trong giai đoạn kiểm thử, UAV thường dao động quanh vị trí tối ưu dù thông lượng không còn cải thiện, gây lãng phí năng lượng. Để khắc phục hiện tượng này, một mô-đun

tính chỉnh hành động dựa trên LLM được tích hợp. LLM không thay thế MADRL mà đóng vai trò lớp kiểm chứng và tính chỉnh quyết định.

Thông tin trạng thái UAV và môi trường được chuyển thành prompt ngôn ngữ tự nhiên có cấu trúc, cho phép LLM đánh giá tính hợp lý của hành động do MADRL đề xuất. Nếu hành động không mang lại cải thiện đáng kể, LLM sẽ đề xuất một hành động tiết kiệm năng lượng hơn.

Cơ chế này giúp kết hợp khả năng tối ưu chính sách của RL với lập luận theo ngữ cảnh của LLM, tạo thành một khung quyết định hợp tác, hiệu quả và tiết kiệm năng lượng cho điều khiển UAV.



Hình 2 : Kiến trúc tổng thể của hệ thống

Algorithm 2 Evaluation Process with LLM-Assisted Multi-Agent UAV Decision

```

1: Initialize environment and load trained networks  $Q_i^{UAV}$  and  $Q^{HAP}$ 
2: Load parameters  $\theta_i^{UAV}$  and  $\theta^{HAP}$  from saved models
3: Reset environment
4: while  $t < T$  do
5:   Build observation  $s_t^{HAP}$  and select action  $a_t^{HAP}$  via  $Q^{HAP}$ 
6:   Choose satellite to connect following  $a_t^{HAP}$ 
7:   Compute HAP bandwidth  $B_t$ 
8:   Build observation  $s_{i,t}^{UAV}$  for each UAV  $i$ 
9:   Select actions  $a_{i,t}^{UAV}$ 
10:  if  $start < t < end$  then
11:    Compute current throughput  $R_{i,t}^{UAV}$  under limit backhaul capacity from  $B_t$ 
12:    Build observation  $\hat{s}_t^{HAP}$  and select action  $\hat{a}_t^{HAP}$  via  $Q^{HAP}$ 
13:    Choose satellite to connect following  $\hat{a}_t^{HAP}$ 
14:    Estimate HAP bandwidth  $\hat{B}_t$  if UAVs move following  $a_{i,t}^{UAV}$ 
15:    Estimate throughput  $\hat{R}_{i,t}^{UAV}$  if UAVs move following  $a_{i,t}^{UAV}$  under limit backhaul capacity from  $\hat{B}_t$ 
16:    Generate the structured prompt  $\Omega_t$  from  $\{[s_{i,t}^{UAV}, a_{i,t}^{UAV}] \mid i \in M, R_{i,t}^{UAV}, \hat{R}_{i,t}^{UAV}\}$ 
17:    Get output  $O_t$  from  $P_{LLM}(\Omega_t)$ 
18:    Parse the response  $O_t$  using regex to obtain the final actions  $a_{i,t}^{UAV\_Final}$ 
19:  else
20:     $a_{i,t}^{UAV\_Final} = a_{i,t}^{UAV}$ 
21:  end if
22:  Compute current throughput  $R_{i,t}^{UAV}$  under limit backhaul capacity from  $B_t$ 
23:  Execute  $a_{i,t}^{UAV\_Final}$ 
24:  Update environment

```

Luồng khi testing

5. Đánh giá độ phức tạp/ tốc độ hội tụ của hệ thống

Kích thước mô hình:

Kích thước mô hình cho mỗi UAV:

```

QNetwork_UAV(
  (layer1): Linear(in_features=142, out_features=256, bias=True)
  (layer2): Linear(in_features=256, out_features=128, bias=True)
  (layer3): Linear(in_features=128, out_features=64, bias=True)
  (layer4): Linear(in_features=64, out_features=5, bias=True)
)
Total parameters: 78085
Trainable parameters: 78085

```

Trong nghiên cứu này, mỗi UAV được trang bị một Q-network dựa trên Deep Reinforcement Learning (DRL) để ra quyết định điều khiển. Kiến trúc Q-network là một mạng nơ-ron truyền thẳng nhiều lớp (MLP) gồm bốn lớp fully-connected

Độ phức tạp tính toán

Độ phức tạp tính toán của mô hình DRL chủ yếu phát sinh từ các phép nhân–cộng (Multiply–Accumulate, MAC) trong quá trình truyền xuôi (forward pass) và lan truyền ngược (backpropagation) của mạng nơ-ron.

Đối với một UAV, chi phí tính toán của một lần suy luận (inference) tại mỗi bước thời gian được quyết định bởi các lớp fully-connected của Q-network. Với kiến trúc mạng gồm các lớp có kích thước

$142 \rightarrow 256 \rightarrow 128 \rightarrow 64 \rightarrow 5$, số lượng phép MACs cần thiết cho một lần truyền xuôi có thể được biểu diễn như sau:

$$\text{MACs}_{\text{inf}} = 142 \times 256 + 256 \times 128 + 128 \times 64 + 64 \times 5.$$

Do mỗi phép MAC bao gồm một phép nhân và một phép cộng, số lượng floating-point operations (FLOPs) tương ứng cho một lần suy luận được tính là:

$$\text{FLOPs}_{\text{inf}} = 2 \times \text{MACs}_{\text{inf}} = 2(142 \times 256 + 256 \times 128 + 128 \times 64 + 64 \times 5),$$

tương đương khoảng 1.55×10^5 FLOPs cho mỗi bước thời gian.

Đối với các lớp fully-connected, số lượng MACs (và FLOPs) tỉ lệ tuyến tính với số lượng tham số của từng lớp. Do đó, tổng chi phí tính toán cho một lần suy luận của Q-network tại UAV tỉ lệ thuận với tổng số tham số có thể huấn luyện, và có thể được biểu diễn dưới dạng tiệm cận là:

$$\mathcal{O}(|\theta|),$$

trong đó $|\theta|$ là tổng số tham số có thể huấn luyện của mạng.

Khi có N_u UAV hoạt động đồng thời trong mô hình học tăng cường đa tác tử, tổng độ phức tạp suy luận của toàn hệ thống tại mỗi bước thời gian tăng tuyến tính theo số lượng UAV và được biểu diễn là:

$$\mathcal{O}(N_u \cdot |\theta|),$$

tương đương với:

$$\text{FLOPs}_{\text{system}} \approx N_u \cdot \text{FLOPs}_{\text{inf}}.$$

Trong giai đoạn huấn luyện, quá trình cập nhật tham số sử dụng thuật toán lan truyền ngược với batch size là B . Do đó, số lượng phép MACs và FLOPs cho mỗi bước huấn luyện của một UAV tỷ lệ thuận với B , dẫn đến độ phức tạp huấn luyện:

$$\mathcal{O}(B \cdot |\theta|),$$

và với N_u UAV, tổng độ phức tạp huấn luyện của hệ thống là:

$$\mathcal{O}(N_u \cdot B \cdot |\theta|).$$

Độ phức tạp bộ nhớ

Về yêu cầu bộ nhớ, mỗi UAV cần lưu trữ các tham số của Q-network với độ phức tạp bộ nhớ là:

$$\mathcal{O}(|\theta|),$$

ngoài ra còn cần bộ nhớ cho **replay buffer**, với độ phức tạp:

$$\mathcal{O}(L \cdot n_{\text{obs}}),$$

trong đó L là dung lượng của replay buffer và n_{obs} là chiều của không gian quan sát.

Kích thước mô hình cho mỗi HAP:

```
QNetwork_HAP(  
  (layer1): Linear(in_features=63, out_features=256, bias=True)  
  (layer2): Linear(in_features=256, out_features=128, bias=True)  
  (layer3): Linear(in_features=128, out_features=64, bias=True)  
  (layer4): Linear(in_features=64, out_features=36, bias=True)  
)  
Total parameters: 59876  
Trainable parameters: 59876
```

Tương tự như cách tính đối với UAV, độ phức tạp tính toán của mô hình DRL tại **HAP** chủ yếu đến từ các phép nhân-cộng (Multiply-Accumulate, MAC) trong quá trình truyền xuôi và lan truyền ngược của Q-network.

Cụ thể, độ phức tạp suy luận (**inference**) cho một HAP tại mỗi bước thời gian, với kiến trúc Q-network gồm các lớp có kích thước

$63 \rightarrow 256 \rightarrow 128 \rightarrow 64 \rightarrow 36$, có thể được biểu diễn thông qua số lượng **MACs** như sau:

$$\text{MACs}_{\text{HAP}} = 63 \times 256 + 256 \times 128 + 128 \times 64 + 64 \times 36.$$

Do mỗi phép MAC tương ứng với hai phép toán dấu phẩy động, số lượng floating-point operations (FLOPs) cần thiết cho một lần suy luận tại HAP được tính là:

$$\text{FLOPs}_{\text{HAP}} = 2 \times \text{MACs}_{\text{HAP}} = 2(63 \times 256 + 256 \times 128 + 128 \times 64 + 64 \times 36).$$

Đối với các lớp fully-connected, số lượng MACs (và FLOPs) tỉ lệ tuyến tính với số lượng tham số của từng lớp. Do đó, tổng chi phí tính toán cho một lần suy luận của Q-network tại HAP tỉ lệ thuận với tổng số tham số có thể huấn luyện, và có thể được biểu diễn dưới dạng tiệm cận là:

$$\mathcal{O}(|\theta_H|),$$

trong đó $|\theta_H|$ là tổng số tham số có thể huấn luyện của Q-network tại HAP.

Do hệ thống chỉ bao gồm một HAP, độ phức tạp suy luận của toàn bộ mô hình DRL tại mỗi bước thời gian được giữ ở mức:

$$\mathcal{O}(|\theta_H|),$$

đáp ứng yêu cầu ra quyết định **theo thời gian thực**.

Trong giai đoạn huấn luyện, với **batch size** là B , quá trình cập nhật tham số thông qua lan truyền ngược làm phát sinh số lượng MACs và FLOPs tỷ lệ thuận với B . Do đó, độ phức tạp huấn luyện của mô hình DRL tại HAP được biểu diễn là:

$$\mathcal{O}(B \cdot |\theta_H|).$$

Quá trình huấn luyện được thực hiện **offline**, vì vậy không ảnh hưởng trực tiếp đến độ trễ vận hành của hệ thống trong giai đoạn khai thác.

Độ phức tạp bộ nhớ (HAP)

Về yêu cầu bộ nhớ, mô hình HAP cần lưu trữ các tham số của Q-network với độ phức tạp bộ nhớ là:


$$\mathcal{O}(|\theta_H|),$$

ngoài ra còn cần bộ nhớ cho **replay buffer**, với độ phức tạp:

$$\mathcal{O}(L \cdot 63),$$

trong đó L là số lượng mẫu kinh nghiệm được lưu trữ trong replay buffer, và 63 là chiều của không gian quan sát tại HAP.

Tốc độ hội tụ



Hình 3: Tốc độ hội tụ của mô hình HAP và UAV

Như thể hiện trong Hình 3, phần thưởng của tác tử HAP trong khuôn khổ SARL tăng nhanh trong giai đoạn huấn luyện ban đầu và dần hội tụ về một giá trị ổn định sau khoảng 200–300 tập huấn luyện. Điều này cho thấy tác tử HAP đã học được và ổn định hóa chính sách lựa chọn vệ tinh phù hợp, từ đó duy trì các kết nối vệ tinh hiệu quả và đáng tin cậy.

Trong Hình 4, ba UAV trong mô hình MARL thể hiện giá trị phần thưởng dao động nhưng có xu hướng tăng dần theo số tập huấn luyện, và đạt trạng thái ổn định sau khoảng 500 tập. Xu hướng này chứng tỏ mỗi UAV đã từng bước thích nghi với môi trường động và học được các chiến lược điều khiển phù hợp, giúp cải thiện quyết định phân bố vị trí và phục vụ người dùng nhằm đạt được phần thưởng cao hơn.

6. Phân tích kết quả

6.1. Thiết lập môi trường đánh giá

Để mô phỏng các kịch bản truyền thông phi mặt đất (non-terrestrial communication) một cách sát với thực tế nhất có thể, chúng tôi sử dụng dữ liệu thực từ hệ thống STARLINK để mô phỏng các vệ tinh nằm trong bán kính 500 km xung quanh tọa độ trung tâm (35.6762° Bắc, 139.6503° Đông). Đồng thời, $M = 3$ UAV được triển khai để cung cấp vùng phủ sóng cho một khu vực $1.5 \text{ km} \times 1.5 \text{ km}$, với cùng tọa độ trung tâm, nhằm phục vụ $N = 200$ người dùng di động. Phân bố người dùng và mô hình đám mây được xây dựng theo phương pháp mô tả trong [22].

Tham số	Ký hiệu	Giá trị
Góc phân kỳ vệ tinh	θ_{div}^S	20 μrad
Công suất phát vệ tinh	$P_{s,t}^{FSO}$	15 dBm
Góc rung vệ tinh	θ_{sx}, θ_{sy}	0.3 μrad
Băng thông SAT–HAP	$B_{SAT \rightarrow HAP}^{FSO}$	1550 MHz
Độ cao HAP	H_H	20 km
Công suất phát HAP	$P_{i,t}^{FSO}$	6 dBm
Băng thông HAP–UAV	$B_{HAP \rightarrow UAV}^{FSO}$	3 GHz

Tham số	Ký hiệu	Giá trị
Góc phân kỳ HAP	θ_{div}^H	1 mrad
Góc rung HAP	θ_{Hx}, θ_{Hy}	50 μ rad
Đường kính khẩu thu	D_r	8 cm
Độ cao UAV	H_U	250 m
Độ lệch chuẩn nhiễu (HAP & UAV)	$\sigma_n, \sigma_{n,i}$	10^{-7} A/Hz
Bước sóng quang	λ	1.55 μ m
Mức nhiễu loạn khí quyển	$C_n^2(0)$	10^{-13} m ^{-2/3}
Mật độ giọt mây	$N_{c,i}$	250 cm ⁻³
Độ cao tầng khí quyển	H_a	20 km
Độ dày mây theo phương thẳng đứng	H_{cl}	2 km
Tốc độ gió	v_{wind}	21 m/s
Tham số tầng bình lưu	α	2×10^{-2}
Độ cao tầng bình lưu	H_{st}	28 km

Bảng I : Các tham số của liên kết backhaul (FSO)

Trong giai đoạn huấn luyện, tại đầu mỗi tập (episode), chúng tôi ngẫu nhiên chọn một thời điểm trong ngày để trích xuất thông tin về các vệ tinh xuất hiện trong toàn bộ khoảng thời gian mô phỏng tiếp theo. HAP được cố định tại trung tâm khu vực ở độ cao 20 km, trong khi vị trí ban đầu của các UAV được khởi tạo ngẫu nhiên nhằm tăng khả năng tổng quát hóa của mô hình học tăng cường đối với nhiều kịch bản khác nhau.

Mỗi UAV hoạt động ở độ cao cố định 250 m, với bán kính phủ sóng 250 m, cho phép linh hoạt điều chỉnh vị trí để tối ưu hiệu năng mạng, đồng thời vẫn đảm bảo cung cấp dịch vụ truy nhập cục bộ cho người dùng di động.

Các tham số liên quan đến liên kết backhaul FSO, liên kết truy nhập RF, và mô hình DRL được sử dụng trong mô phỏng được tổng hợp trong Bảng I–III, trong khi các tham số UAV phục vụ cho tính toán năng lượng tiêu thụ được lấy theo thiết lập trong [19].

Tham số	Ký hiệu	Giá trị
Công suất phát HAP	$P_{t,H}^{RF}$	40 dBm
Công suất phát UAV	$P_{t,U}^{RF}$	35 dBm
Băng thông RF	B_{RF}	600 MHz
Tần số sóng mang	f_c	2 GHz
Tham số môi trường	(a, b)	(9.61, 0.16)
Suy hao dư	(ξ_{LOS}, ξ_{NLOS})	(1 dB, 20 dB)
Công suất nhiễu	N_0	−80.4 dBm

Bảng II : Các tham số của liên kết truy nhập (RF)

Tham số	Ký hiệu	Giá trị
Tốc độ học	κ	0.001
Hệ số chiết khấu	γ	0.99
Thời lượng mỗi time slot	Δt	1 s
Số slot huấn luyện	T_{train}	300
Số slot kiểm tra	T_{test}	500

Bảng III: Các tham số của mô hình DQN

Tham số SARL (HAP):

- Hệ số tỉ lệ: $(w_v, w_b) = (0.1, 10^{-9})$

- Hệ số phạt handover: $\xi = 40$

- Phạt mất kết nối: $-\zeta = 20$

Tham số MARL (UAV):

- Tỉ lệ trọng số reward: $w = 0.3$


- Hệ số phạt chồng lấp: $p = 0.5$

- Ngưỡng tốc độ dữ liệu: $R_{thres} = 0.6\text{Gbps}$


- Hệ số reward toàn cục: $w_g = 5.56 \times 10^{-10}$

- Hệ số reward cục bộ: $w_l = 1.67 \times 10^{-9}$

Để tích hợp LLM vào khung MARL, chúng tôi sử dụng Gemini để hỗ trợ các UAV trong khoảng từ bước 200 đến bước 450. LLM không được áp dụng trong toàn bộ quá trình mô phỏng, do việc sử dụng liên tục có thể làm giảm khả năng khám phá (exploration) của mô hình DQN. Hình 4 và Hình 5 là môi trường mô phỏng hệ thống trong 1 vài step




Hình 4: Môi trường mô phỏng vệ tinh



Hình 5: Môi trường mô phỏng UAV và người dùng và mây

6.2. Đánh giá kết quả


Để đánh giá kết quả, nhóm đã thực hiện mô phỏng 100 episode, mỗi episode gồm 500 bước thời gian. Ở đầu mỗi tập (episode), kịch bản vệ tinh, bản đồ mây và vị trí người dùng được khởi tạo ngẫu nhiên nhằm tạo ra môi trường biến thiên, trong khi tất cả các UAV được triển khai từ cùng một vị trí xuất phát tại tọa độ $[0, 0]$. Để đánh giá tính ổn định của chính sách lựa chọn vệ tinh, chúng tôi so sánh phương pháp đề xuất với hai thuật toán tham chiếu: (i) lựa chọn vệ tinh có dung lượng backhaul lớn nhất (MCF SO) và (ii) lựa chọn vệ tinh có thời gian khả kiến dài nhất (MVT).



Hình 6: So sánh chính sách lựa chọn vệ tinh của nhóm so với 2 cách chọn vệ tinh theo ngưỡng

Như thể hiện trong hình 6, chính sách lựa chọn vệ tinh dựa trên phương pháp đề xuất cho thấy độ ổn định và hiệu quả cao hơn so với các phương pháp khác. Phương pháp này giúp hệ thống thích nghi tốt với sự thay đổi vị trí liên tục của các vệ tinh, giảm tần suất chuyển giao (handover) không cần thiết, và duy trì dung

lượng đường truyền backhaul ở mức ổn định hơn. Ngoài ra, phương pháp đề xuất có xu hướng lựa chọn các vệ tinh cung cấp liên kết đáng tin cậy và có tính dài hạn cao, thay vì chỉ tập trung vào dung lượng tức thời, qua đó đạt được sự cân bằng giữa hiệu năng và độ ổn định kết nối. Xu hướng này cho thấy mô hình đã học được một chính sách lựa chọn vệ tinh hợp lý hơn trong các điều kiện môi trường biến động.




Hình 7 : Backhaul capacity và thông lượng người dùng trong 1 episode

Hình 7 minh họa dung lượng backhaul của liên kết SAT–HAP, dung lượng backhaul của liên kết HAP–UAV, và tổng tốc độ dữ liệu mà UAV cung cấp cho người dùng trong suốt quá trình mô phỏng.

Kết quả cho thấy khung hệ thống có khả năng linh hoạt điều chỉnh quỹ đạo UAV để thích nghi với sự thay đổi của kênh truyền, đồng thời lựa chọn vệ tinh kết nối một cách phù hợp theo thời gian. Liên kết SAT–HAP duy trì dung lượng backhaul ở mức đủ lớn để đáp ứng nhu cầu của liên kết HAP–UAV, vốn dao động mạnh do ảnh hưởng của mây và sự di chuyển của UAV, qua đó chứng tỏ chính sách lựa chọn vệ tinh cho kết nối là tối ưu.


Đồng thời, tốc độ dữ liệu cung cấp cho người dùng luôn tuân thủ giới hạn trên của dung lượng backhaul HAP–UAV, cho thấy vị trí UAV theo thời gian cũng đã được tối ưu nhằm giảm thiểu nút thắt cổ chai tại lớp backhaul. Nhờ khả năng phản ứng nhanh với chuyển động của vệ tinh, sự thay đổi vị trí người dùng và các dao động do mây gây ra, hệ thống duy trì được thông lượng đầu cuối ổn định, từ đó cải thiện hiệu năng mạng trong các điều kiện môi trường có mức biến động cao.



Hình 8: So sánh thông lượng trung bình mà các UAV cung cấp cho người dùng

Tiếp theo để xem xét lưu lượng người dùng mà các UAV cung cấp là tối ưu hay không (Hình 8), nhóm tiến hành so sánh giữa mô hình đề xuất so với mô hình tương tự nhưng trạng thái đầu vào của nó loại bỏ đi các thông tin liên quan đến bản đồ mây (Proposed-NC). Kết quả cho thấy mô hình đề xuất (Proposed) thông lượng trung bình cung cấp cho người dùng trong 100 episode test cho ra kết quả cao hơn so với mô hình khi bỏ đi quan sát liên quan đến bản đồ mây, chứng tỏ thuật toán mà nhóm đề xuất đã tối ưu tốt vị trí của các UAV để cung cấp cho người dùng thông lượng cao nhất có thể.

Cuối cùng nhóm tiến hành so sánh độ hiệu quả của LLM (Hình 9) trong việc cải thiện chính sách ra quyết định cho UAV di chuyển. Có thể thấy khi áp dụng LLM vào mô hình hệ thống thì mức năng lượng của mỗi UAV tiêu thụ là thấp hơn rất nhiều so với khi không áp dụng, hơn nữa thông lượng trung bình mà mỗi UAV cung cấp cho người dùng cũng không thấp hơn quá nhiều (UAV1) mà thậm chí còn cao hơn (UAV2, UAV3) so với khi không áp dụng LLM.



Hình 9 : So sánh độ hiệu quả khi áp dụng LLM vào hệ thống

7. Kết luận

Nhóm em đã đề xuất một khung tối ưu hóa đầu-cuối cho mạng tích hợp vệ tinh – HAP – UAV, được xây dựng dựa trên học tăng cường sâu (Deep Reinforcement Learning – DRL) nhằm đồng thời giải quyết hai bài toán quan trọng: lựa chọn vệ tinh tối ưu cho HAP và tối ưu vị trí UAV trong môi trường có tính động cao.

Môi trường được xét thay đổi liên tục do sự xuất hiện của nhiều vệ tinh quỹ đạo thấp (LEO) tại mỗi thời điểm, kết hợp với vận tốc quỹ đạo rất lớn của vệ tinh. Bên cạnh đó, chuyển động ngẫu nhiên của người dùng mặt đất và sự biến thiên theo thời gian của mật độ nước lỏng trong mây (CLWC) càng làm gia tăng độ phức tạp của hệ thống, gây khó khăn trong việc duy trì các liên kết ổn định giữa các lớp mạng.

Mục tiêu chính của khung đề xuất là duy trì liên kết backhaul ổn định giữa HAP và vệ tinh, đảm bảo dung lượng FSO đủ lớn để cung cấp dữ liệu cho các UAV, đồng thời xác định vị trí UAV tối ưu nhằm cực đại hóa tổng thông lượng người dùng (sum-rate), trong khi vẫn thỏa mãn các ràng buộc về công suất và băng thông của cả liên kết truy nhập và liên kết backhaul động.

Ngoài ra, mô hình ngôn ngữ lớn Gemini (LLM) được tích hợp nhằm hỗ trợ quá trình ra quyết định của UAV trong giai đoạn trung gian của quá trình huấn luyện, giúp ổn định quá trình học, giảm dao động chính sách, và tiết kiệm năng lượng trong vận hành dài hạn.

Nhờ tận dụng cơ chế học liên tục của học tăng cường sâu, các tác tử HAP và UAV có khả năng thích nghi linh hoạt với sự thay đổi của môi trường, tự động tối ưu chiến lược lựa chọn vệ tinh và quỹ đạo bay, từ đó nâng cao hiệu năng kết nối và chất lượng dịch vụ (QoS) cho toàn bộ hệ thống. Các mô phỏng quy mô lớn trong nhiều kịch bản khác nhau cho thấy khung đề xuất hoạt động hiệu quả, giúp các tác tử học được các chiến lược thích nghi thông minh, duy trì tính ổn định của mạng và tối ưu hiệu năng tổng thể của hệ thống.

Tài liệu tham khảo

- [1] D. V. Huynh, S. R. Khosravirad, S. L. Cotton, H. Shin, and T. Q. Duong, “Multi-agent reinforcement learning for optimal resource allocation in space–air–ground integrated networks,” *IEEE Internet of Things Journal*, pp. 1–11, 2025.
- [2] Y.-J. Chen, W. Chen, and M.-L. Ku, “Trajectory design and link selection in UAV-assisted hybrid satellite–terrestrial networks,” *IEEE Communications Letters*, vol. 26, no. 7, pp. 1643–1647, Jul. 2022.
- [3] J.-H. Lee, J. Park, M. Bennis, and Y.-C. Ko, “Integrating LEO satellite and UAV relaying via reinforcement learning for non-terrestrial networks,” in *Proc. IEEE GLOBECOM*, Taipei, Taiwan, 2020, pp. 1–6.
- [4] E. M. Mohamed, M. A. Alnakhli, and M. M. Fouda, “Joint UAV trajectory planning and LEO satellite selection in SAGIN,” *IEEE Open Journal of the Communications Society*, vol. 5, pp. 1624–1638, 2024.
- [5] M. A. Khalighi and M. Uysal, “Survey on free space optical communication: A communication theory perspective,” *IEEE Communications Surveys & Tutorials*, vol. 16, no. 4, pp. 2231–2258, 2014.
- [6] S. Liu, H. Dahrouj, and M.-S. Alouini, “Joint user association and beamforming in integrated satellite–HAPS–ground networks,” *IEEE Transactions on Vehicular Technology*, vol. 73, no. 4, pp. 5162–5178, Apr. 2024.
- [7] Y. Guan, S. Zou, H. Peng, W. Ni, Y. Sun, and H. Gao, “Cooperative UAV trajectory design for disaster area emergency communications: A multi-agent PPO method,” *IEEE Internet of Things Journal*, vol. 11, no. 5, pp. 8848–8859, Mar. 2024.
- [8] L. Yu, X. Sun, S. Shao, Y. Chen, and R. Albelaihi, “Backhaul-aware drone base station placement and resource management for FSO-based drone-assisted mobile

networks,” *IEEE Transactions on Network Science and Engineering*, vol. 10, no. 3, pp. 1659–1668, 2023.

[9] J. Li *et al.*, “LLM-guided DRL for multi-tier LEO satellite networks with hybrid FSO/RF links,” *arXiv preprint* arXiv:2505.11978, 2025, submitted to *IEEE JSAC*.

[10] C. Xu *et al.*, “TellDrive: Enhancing autonomous driving with teacher LLM-guided deep reinforcement learning,” *arXiv preprint* arXiv:2502.01387, 2025.

[11] A. Pang *et al.*, “iLLM-TSC: Integration of reinforcement learning and large language models for traffic signal control policy improvement,” *arXiv preprint* arXiv:2407.06025, 2024.

[12] H. Tan, H. Yan, and Y. Yang, “LLM-guided reinforcement learning: Addressing training bottlenecks through policy modulation,” *arXiv preprint* arXiv:2505.20671, 2025.

[13] Starlink, “Starlink official website.” [Online]. Available: <https://www.starlink.com/>. Accessed: May 2020.

[14] W. Zhang, R. Deng, B. Di, and L. Song, “Integrated satellite–HAP–terrestrial networks for dual-band connectivity,” *arXiv preprint* arXiv:2107.02336, 2021.

[15] H. Zhang *et al.*, “5G network on wings: A deep reinforcement learning approach to UAV-based integrated access and backhaul,” *IEEE Transactions on Machine Learning in Communications and Networking*, vol. 2, pp. 1109–1126, 2024.

[16] E. Erdogan, I. Altunbas, G. K. Kurt, and H. Yanikomeroglu, “Cooperation in space: HAPS-aided optical inter-satellite connectivity with opportunistic scheduling,” *IEEE Communications Letters*, vol. 26, no. 4, pp. 882–886, Apr. 2022.

[17] D. Giggenbach, R. Purvinskis, M. Werner, and M. Holzbock, “Stratospheric optical inter-platform links for high altitude platforms,” in *Proc. ICSSC*, 2002, Art. no. 1910.

[18] H. D. Le, H. D. Nguyen, C. T. Nguyen, and A. T. Pham, “FSO-based space–air–ground integrated vehicular networks: Cooperative HARQ with rate adaptation,” *IEEE Transactions on Aerospace and Electronic Systems*, vol. 59, no. 4, pp. 4076–4091, Aug. 2023.

- [19] R. Ding, F. Gao, and X. S. Shen, “3D UAV trajectory design and frequency band allocation for energy-efficient and fair communication: A deep reinforcement learning approach,” *IEEE Transactions on Wireless Communications*, vol. 19, no. 12, pp. 7796–7809, Dec. 2020.
- [20] P. J. Huber, “Robust estimation of a location parameter,” *The Annals of Mathematical Statistics*, vol. 35, no. 1, pp. 73–101, 1964.
- [21] D. A. Vallado, P. Crawford, R. Hujsak, and T. S. Kelso, “Revisiting Spacetrack Report No. 3: Rev. 2,” in *Proc. AIAA/AAS Astrodynamics Specialist Conf.*, 2006.
- [22] T. V. Nguyen, H. D. Le, V. Mai, S. R. Khosravirad, and A. T. Pham, “Deep reinforcement learning for UAV placement over mixed FSO/RF-based non-terrestrial networks,” in *Proc. IEEE APWCS*, 2024, pp. 1–5.